Brecha digital estudiantil en el Perú: integración ENAHO–ESCALE 2025, segmentación, predicción y explicabilidad con SHAP

Moises Joaquin Mestas Maque
Ingeniería de Sistemas
Proyecto de Inteligencia Artificial, corte 2025
Perú

***Resumen*—Se construyó un flujo reproducible de aprendizaje automático para caracterizar y predecir el *no uso de internet durante el mes anterior* en estudiantes de 6–17 años. Se integraron los módulos de vivienda, personas, educación y Sumaria de los microdatos ENAHO proporcionados para la evaluación (panel 2021–2025, corte 2025), con información distrital del Padrón y Padlocal del MINEDU. La tabla resultante contiene 24.195 estudiantes y 75 columnas, sin duplicación de llaves y con coincidencia distrital en todos los registros. Se compararon K-Means y mezclas gaussianas; K-Means con dos grupos obtuvo la mejor silueta de las configuraciones evaluadas (0,2179, estimada en muestra). En clasificación supervisada, HistGradientBoosting fue seleccionado mediante validación cruzada agrupada; en prueba aislada obtuvo ROC-AUC de 0,8372, precisión promedio (AP) de 0,6780 y recall de la clase no uso de 0,4808. Una búsqueda aleatoria de 12 configuraciones elevó el AP medio de validación de 0,659338 a 0,662398, sin sustituir el modelo final. SHAP identificó la edad como el predictor de mayor contribución media absoluta. Los resultados son descriptivos y predictivos para la base disponible, no estimaciones causales ni representativas a escala nacional.**

***Index Terms*—brecha digital, ENAHO, ESCALE, K-Means, HistGradientBoosting, SHAP, validación agrupada.**

I. Introducción

La brecha digital estudiantil involucra desigualdades en el uso de tecnologías y en las condiciones socioeconómicas y territoriales que las acompañan. La práctica del curso plantea integrar microdatos ENAHO y ESCALE, descubrir perfiles con aprendizaje no supervisado, comparar clasificadores e interpretar las decisiones con SHAP [1]. La pregunta operativa abordada es: *¿hasta qué punto las características del estudiante, del hogar y de su distrito permiten distinguir a quienes no usaron internet durante el mes anterior?* Esta definición es deliberadamente más acotada que la *exclusión digital efectiva* sugerida por la guía: no mide competencias digitales ni rendimiento escolar. El objetivo es presentar un flujo auditable sin transformar una etiqueta observada en una afirmación causal.

II. Datos y metodología

II-A. Fuentes, llaves y cobertura

Se usaron exclusivamente los archivos recibidos en la evaluación: ENAHO módulos 100 (vivienda), 200 (personas), 300 (educación/TIC) y Sumaria (economía del hogar) [2]; y archivos Padrón y Padlocal del MINEDU/ESCALE [3]. Los microdatos ENAHO disponibles corresponden a un *panel 2021–2025*, filtrado a 2025, no a un archivo anual completo independiente. Se conservaron como texto las llaves `AÑO`, `CONGLOME`, `VIVIENDA`, `HOGAR`, `CODPERSO` y `UBIGEO`, preservando ceros a la izquierda.

El cruce por persona empleó año, conglomerado, vivienda, hogar y código de persona; las tablas de hogar se anexaron con su llave correspondiente. Los datos escolares fueron agregados por distrito, uniendo `CODGEO` con `UBIGEO`. Se derivaron la razón distrital de alumnos por docente, la proporción de instituciones públicas/privadas y coordenadas medias. No se atribuyen estas variables al colegio concreto del estudiante. La tabla final contiene 24.195 casos de 6–17 años y 75 columnas: cero llaves duplicadas o incompletas, 100 % de `UBIGEO` válidos y coincidencia MINEDU en todos los casos. Se conservaron 527 estudiantes sin cruce con el módulo educativo, en lugar de eliminarlos sin fundamento.

II-B. Prevención de fuga y preprocesamiento

La etiqueta se definió según el cuestionario ENAHO: `P314A=2` significa *no utilizó internet en el mes anterior* (clase 1), y `P314A=1`, *sí utilizó internet* (clase 0). Se excluyeron 577 casos sin respuesta: quedaron 23.618 alumnos (17.177 de clase 0 y 6.441 de clase 1). La pregunta `P306` se refiere a matrícula educativa, no a calificaciones.

La separación `GroupShuffleSplit` por conglomerado dejó 17.690 casos en entrenamiento y 5.928 en prueba, con 3.786 y 1.263 conglomerados *disjuntos*, respectivamente. Dentro de entrenamiento se aplicaron tres particiones `GroupKFold`. Imputación, escalado y codificación *one-hot* se ajustaron dentro de cada pliegue mediante `Pipeline`. Los nueve predictores supervisados fueron edad, ingreso/gasto del hogar, razón alumnos/docente, proporción de instituciones públicas, sexo codificado, pobreza y dos variables de vivienda; se excluyeron `EDU_`$\star$, identificadores, `UBIGEO`, factores muestrales y etiquetas exploratorias de clusters. Se fijó semilla 42.

II-C. Modelos y protocolo

Para agrupamiento se compararon K-Means y modelos de mezclas gaussianas (GMM), con $k = 2, \ldots, 6$; ingreso y gasto recibieron transformación arcsinh, escalado numérico y

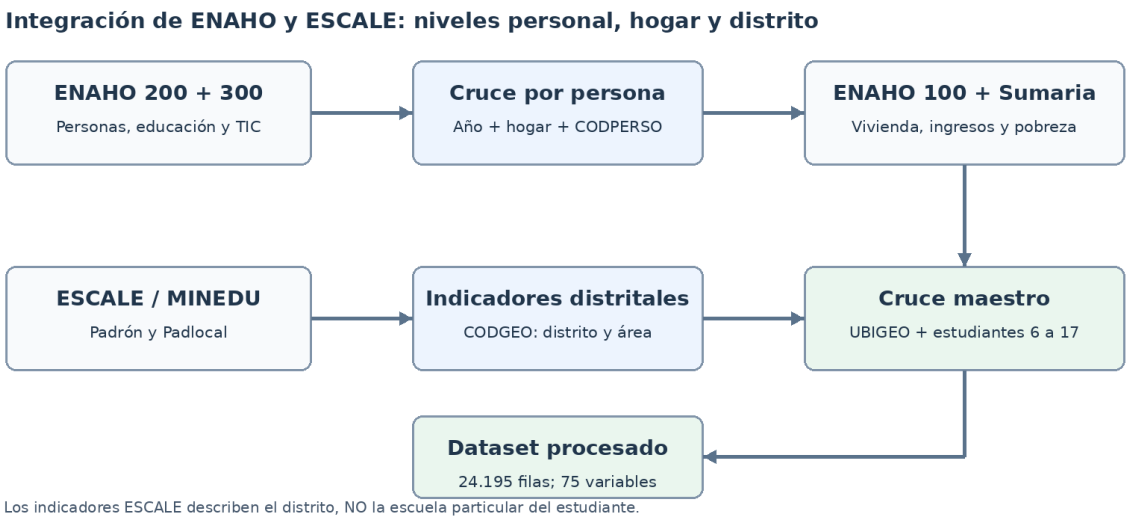


Figura 1. Integración reproducible de módulos ENAHO por llaves de persona/hogar y de indicadores MINEDU agregados por distrito. El cruce no identifica la institución particular del encuestado.

Tabla I
SELECCIÓN DE AGRUPAMIENTO, CON $k = 2$

Método	Silueta	D–B	C–H
K-Means	**0,2179**	**1,720**	**7689,7**
GMM	0,1394	2,876	1685,0

Tabla II
PERFIL DESCRIPTIVO DE DOS CLUSTERS

Medida (mediana salvo n)	C0	C1
Estudiantes, n	13.377	10.818
Edad, años	12	12
Ingreso hogar	47.991	21.106
Gasto hogar	40.268	19.789
Alumnos/docente distrital	17,55	12,84
Proporción pública distrital	0,62	1,00

codificación de categorías. Se valoraron silueta, Davies–Bouldin y Calinski–Harabasz, y se realizó una visualización PCA.

La clasificación incluyó regresión logística como referencia y Random Forest, HistGradientBoosting y perceptrón multicapa (MLP). El criterio de selección fue AP medio en validación cruzada agrupada; el conjunto de prueba se reservó para el modelo escogido. Adicionalmente, `RandomizedSearchCV` examinó 12 configuraciones de HistGradientBoosting solo en entrenamiento. La explicabilidad SHAP se calculó sobre una muestra de 300 observaciones de prueba del modelo original.

III. Resultados: aprendizaje no supervisado

K-Means con dos grupos logró la mayor silueta de las diez configuraciones evaluadas (Tabla I). Su valor de 0,2179, obtenido en una muestra de 1.800, indica *separación limitada*; no prueba perfiles naturalmente nítidos. La gráfica individual de silueta (Fig. 2) utiliza otra muestra de 1.200 estudiantes (media 0,211; grupos de 657 y 543), por lo que ambas cifras no deben confundirse.

Tabla III
COMPARACIÓN EN VALIDACIÓN CRUZADA AGRUPADA (3 FOLDS)

Modelo	ROC-AUC	AP	F1 macro
Regresión logística	0,8254	0,6563	0,7136
Random Forest	0,8211	0,6513	**0,7260**
HistGradientBoosting	0,8251	**0,6593**	0,7105
MLP	0,8204	0,6578	0,7033

El cluster 0 agrupa 13.377 estudiantes (55,29 %) y presenta medianas de ingreso y gasto mayores que el cluster 1, de 10.818 (44,71 %). En el cluster 1 hay más predominio distrital de instituciones públicas. La proporción con `P314A=2` fue 15,71 % en C0 y 40,12 % en C1; esta diferencia *no es evidencia independiente*, pues P314A participó en el agrupamiento exploratorio.

IV. Resultados: clasificación supervisada

Se seleccionó HistGradientBoosting por el AP medio más alto, aunque las diferencias entre modelos son pequeñas (Tabla III) y no se estimaron intervalos de confianza. La prueba aislada reportó ROC-AUC **0,8372**; AP **0,6780**; F1 macro 0,7185; exactitud 0,7999; exactitud balanceada 0,7002; precisión para no uso 0,6913 y *recall* para no uso **0,4808**. La matriz $\left[\begin{smallmatrix} 3965 & 347 \\ 839 & 777 \end{smallmatrix}\right]$ utiliza filas reales y columnas predichas [uso, no uso]. De 1.616 alumnos que no usaron internet, **839 no fueron detectados**; ello limita la aplicación como herramienta de identificación de vulnerabilidad.

IV-A. *Búsqueda de hiperparámetros*

La búsqueda con `RandomizedSearchCV` probó 12 configuraciones y ajustó el preprocesamiento por fold, optimizando *average precision*. El AP medio pasó de **0,659338** (configuración original) a **0,662398** (mejor combinación), diferencia de **0,003060**. Los parámetros seleccionados fueron: `learning_rate=0.07`, `max_iter=110`,

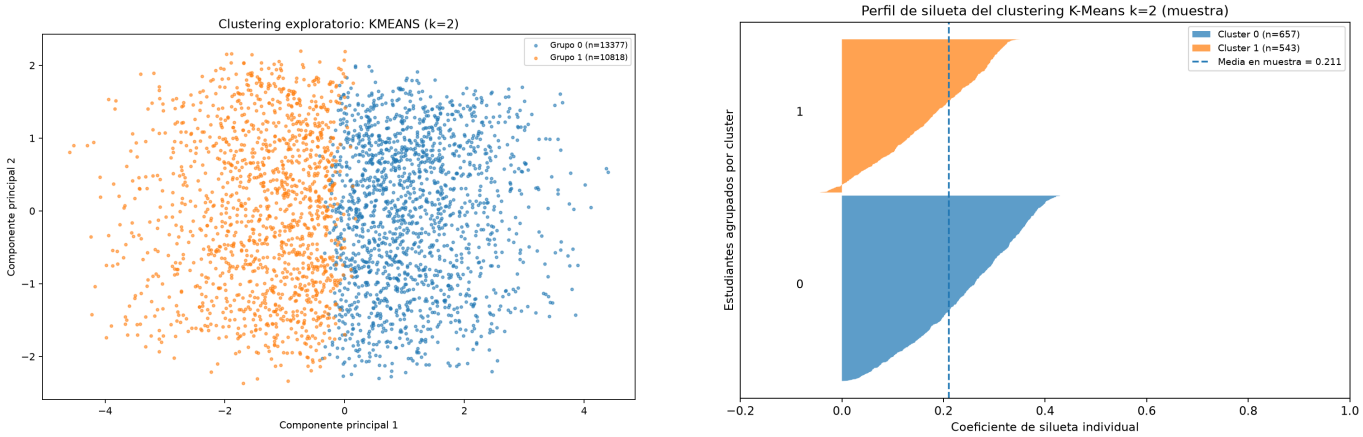


Figura 2. Clustering K-Means, $k = 2$: (izq.) proyección PCA; (der.) perfiles individuales de silueta para una muestra de 1.200 estudiantes. La separación visual y la silueta muestran solapamiento entre grupos.

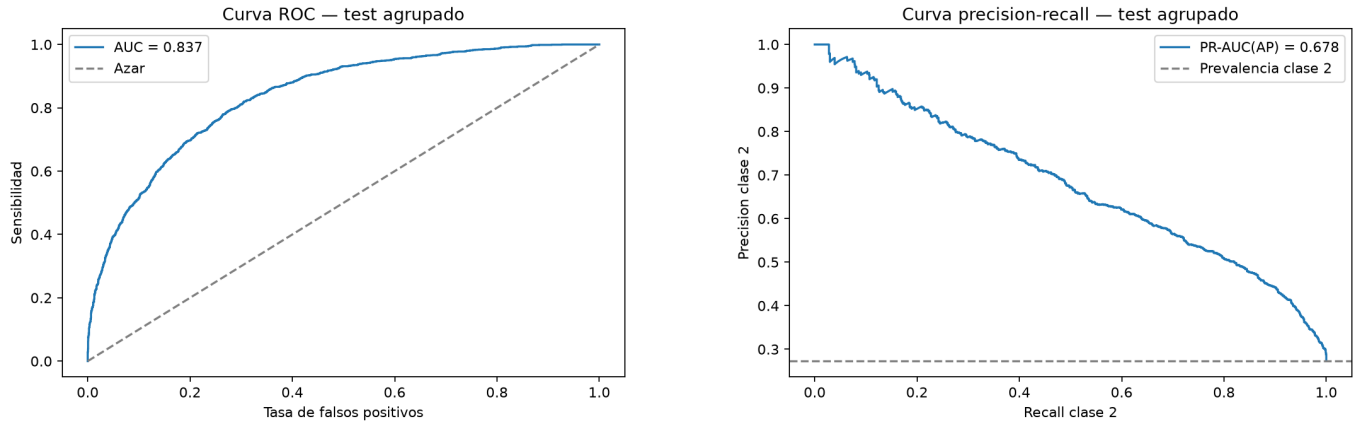


Figura 3. Rendimiento del clasificador final en prueba por conglomerado: curva ROC (AUC = 0,8372) y curva precisión–recall (AP = 0,6780).

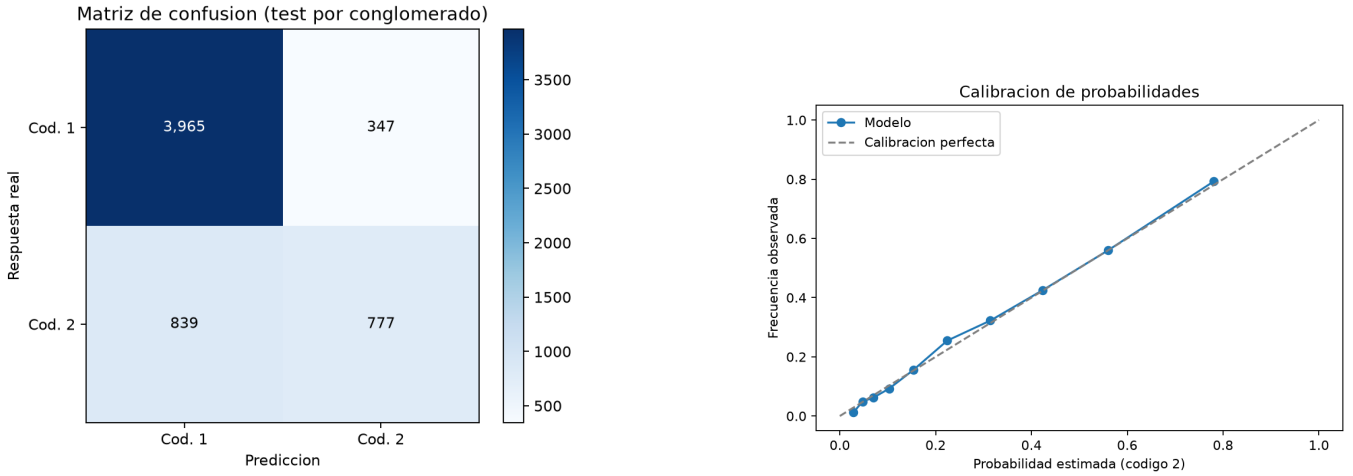


Figura 4. Test del modelo seleccionado: matriz de confusión y curva de calibración. La curva de calibración es descriptiva para los puntos observados.

`max_leaf_nodes=7`, `min_samples_leaf=40` y `l2_regularization=0.0`. Es una mejora pequeña, obtenida durante la selección y potencialmente optimista; *no se evaluó el modelo optimizado en test*, no se sustituyó el

original ni se recalculó SHAP.

V. Explicabilidad SHAP

Las explicaciones se calcularon para 300 estudiantes de prueba con nueve variables originales y 14 columnas transformadas. El error máximo de aditividad informado fue 0,00000000. Los valores SHAP están en *log-odds* para la clase de no uso y describen decisiones del modelo, no efectos causales [4].

La mayor contribución absoluta media correspondió a la **edad** (0,9824), seguida por proporción distrital de instituciones públicas (0,3783), el indicador `POBREZA=3` (0,2408), gasto del hogar (0,2307) y dos indicadores codificados de vivienda (0,1277 y 0,0934). El ranking absoluto no determina el signo de cada contribución. Los gráficos de dependencia muestran la relación modelada, no una relación causal ni necesariamente monótona en unidades originales.

VI. Discusión, limitaciones y uso responsable

El procedimiento reduce la fuga entre observaciones próximas al separar conglomerados y ajustar transformaciones dentro de entrenamiento. Sin embargo, existen limitaciones relevantes: (i) `P314A` mide *uso en el mes anterior*, no la exclusión digital multidimensional ni el rendimiento escolar; (ii) los datos provienen del panel entregado y no equivalen al ENAHO anual completo; (iii) no se efectuó inferencia nacional con factores de expansión y diseño muestral complejo; (iv) el contexto MINEDU es distrital, no de la escuela asistida; (v) la silueta baja y la presencia de P314A en el agrupamiento restringen la interpretación digital de los perfiles; y (vi) el modelo final HistGradientBoosting no fue ponderado por clase ni por factor muestral, aunque el desbalance se tuvo en cuenta mediante métricas AP/F1 y otros clasificadores con ponderación. Tampoco se evaluaron intervalos de confianza ni validación externa.

La tasa de falsos negativos obliga a considerar estrategias de umbral y validación adicional antes de decisiones de política educativa. Las predicciones pueden apoyar *diagnósticos exploratorios*, pero no asignar ni negar automáticamente beneficios a estudiantes. Las características socioeconómicas son asociaciones en la muestra, no causas demostradas.

VII. Conclusiones

La integración ENAHO–MINEDU produjo una tabla coherente de 24.195 alumnos y permitió caracterizar dos perfiles exploratorios de limitada separación. HistGradientBoosting alcanzó ROC-AUC 0,8372 y AP 0,6780, pero detectó menos de la mitad de los casos de no uso reciente de internet. SHAP destacó la edad y rasgos del contexto distrital y económico como componentes de la predicción. La búsqueda de hiperparámetros documentó una mejora pequeña exclusivamente en validación; el resultado de prueba original se mantuvo inalterado. Como pruebas complementarias, el modelo XGBoost aplicado a estudiantes matriculados que asisten alcanzó AP de 0,6421 en prueba y otro XGBoost estimó un índice continuo propio con RMSE de 0,2331; además, se compararon pesos de clase y una ponderación exploratoria. Persisten limitaciones de representatividad y de medición de competencias digitales.

VIII. Reproducibilidad y trazabilidad

El repositorio se organiza en `data/raw` (fuentes), `data/interim` (módulos depurados), `data/processed` (tabla maestra), `src` (scripts) y `outputs` (resultados/modelo). El archivo `dataset_enaho_escale_2025.csv` permite continuar los análisis. La auditoría estructural confirmó 33 de 33 evidencias esperadas, cero duplicados de llaves y cobertura territorial completa; la presencia de archivos no equivale a validación metodológica.

La secuencia ejecutable abarca limpieza ENAHO (script 05), integración de personas y hogares (06), agregación/cruce MINEDU (07), auditoría (08), clustering (09–10), clasificación agrupada (11), SHAP del modelo original (12), silueta (13), verificación de evidencias (14) y búsqueda de hiperparámetros (15). Se conservan `random_state=42`, los tamaños de partición y las métricas; la búsqueda optimizada se almacena separada del clasificador evaluado. Los gráficos proceden de las ejecuciones reales suministradas para este informe.

Referencias

[1] *Proyecto IA: Brecha digital y rendimiento escolar en el Perú*, guía técnica y rúbrica de evaluación, curso de Inteligencia Artificial, corte 2025.

[2] Instituto Nacional de Estadística e Informática (INEI), *ENAHO: módulos 100, 200, 300 y Sumaria; microdatos panel 2021–2025, corte 2025, y cuestionario 2025*, archivos suministrados para la evaluación.

[3] Ministerio de Educación del Perú (MINEDU), *ESCALE: Padrón de Instituciones Educativas y Padlocal, corte 2025*, archivos suministrados para la evaluación.

[4] S. M. Lundberg y S.-I. Lee, "A unified approach to interpreting model predictions," en *Advances in Neural Information Processing Systems*, 2017.

[5] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

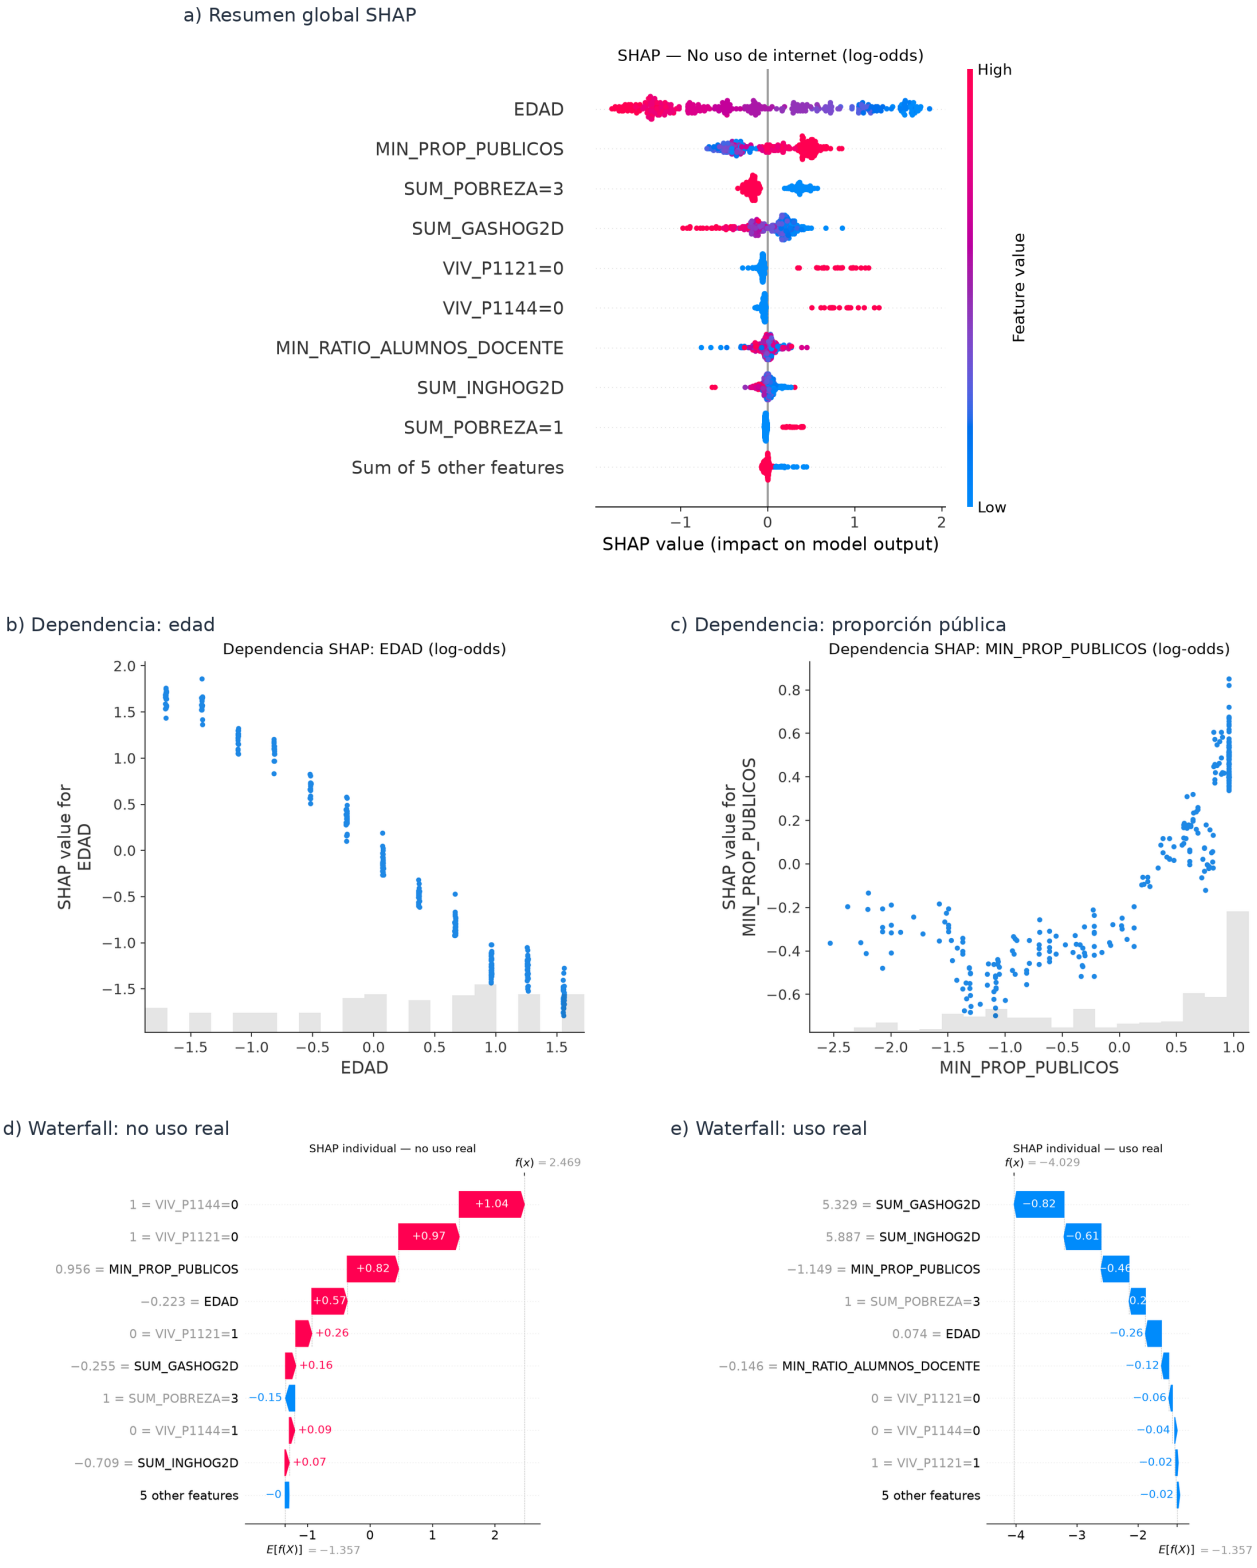


Figura 5. Explicabilidad SHAP sobre 300 estudiantes de prueba. (a) *Beeswarm* global, (b–c) dependencias de edad y proporción pública distrital; (d–e) explicaciones individuales de alto y bajo riesgo (probabilidades de no uso 0,922 y 0,017, respectivamente). Las contribuciones son en log-odds, sin implicación causal.

1. Ampliacion de la clasificacion

Se agregaron **XGBoost** y experimentos con pesos de clase al objetivo original A (no uso reciente de internet). Se compararon mediante **GroupKFold de 3 particiones sobre TRAIN**; estas cifras no son del test.

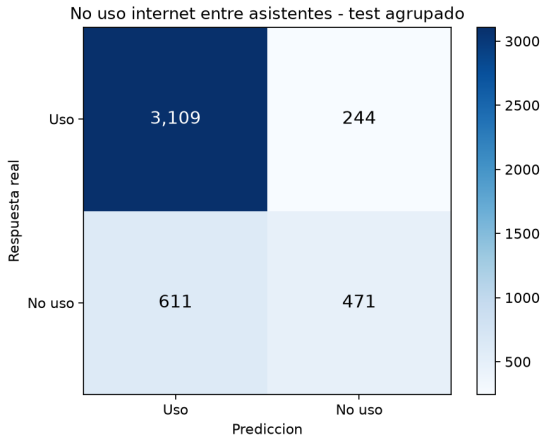
Experimento A	AP (CV)	Recall
XGB sin pesos	0.6649	0.4806
XGB con pesos	0.6647	0.7542
HistGB con pesos	0.6611	0.7485
HistGB original	0.6593	0.4720

2. Clasificacion C: estudiantes asistentes

Nueva cohorte: matriculado **P306=1**, asiste **P307=1**; positivo **P314A=2** (no uso de internet el mes anterior). Esto sigue sin medir habilidades digitales.

Modelo elegido por CV: XGBoost_optimizado_sin_pesos. **Test agrupado:** AP 0.642; ROC-AUC 0.837; F1 macro 0.702; Recall 0.435. N prueba: 4,435.

Modelo (CV train)	AP	Recall
XGBoost_optimizado_sin_pes	0.656	0.454
XGBoost_sin_pesos	0.656	0.463
XGBoost_optimizado_con_pes	0.655	0.765
XGBoost_con_pesos_clase	0.655	0.762

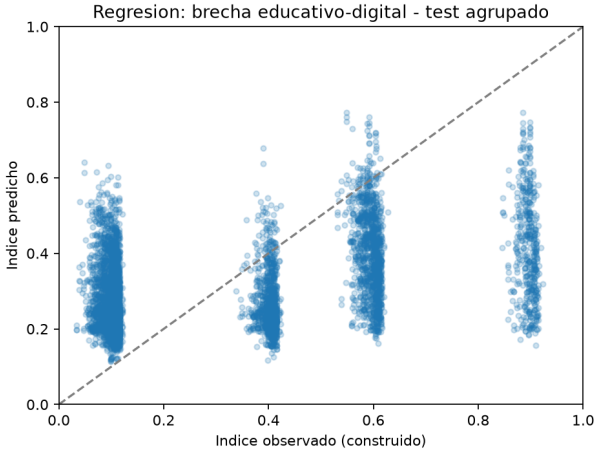


3. Opcion B: indice continuo propuesto

Se construyo un indice propio (escala 0-1): **0.50** por no uso de internet; **0.30** por no asistencia a estudios y **0.20** por presion educativa distrital (alumnos/docente dividido por alumnos/docente + 15). Su definicion no es un estandar INEI.

Modelo elegido por CV: XGBoost_Reg_optimizado. En test: RMSE 0.233; MAE 0.195; R2 0.207. N prueba: 5,928.

Modelo (CV train)	RMSE	R2
XGBoost_Reg_optimizado	0.237	0.189
XGBoost_Reg	0.237	0.186
MLP_Reg	0.238	0.178
HistGB_Reg	0.239	0.176



4. Control metodologico

Sin fugas: particion por conglomerado; transformaciones ajustadas en cada entrenamiento; indicadores que definen el indice excluidos de sus predictores. **Desbalance:** pesos calculados dentro del fold. **Factor07:** sensibilidad en train; sin inferencia nacional porque no se incorporo el diseno muestral complejo. SHAP solo explica predicciones, no causalidad.

5. EDA RAW: REVISION ANTES DEL PREPROCESAMIENTO

EDA previo sobre los ZIP ENAHO (panel 2021-2025, filtro 2025) y DBF MINEDU. Sin imputacion, sin usar el dataset procesado y sin entrenar modelos.

Registros 2025: ENAHO 100=44 599, 200=115 145, 300=106 958, Sumaria=33 702; Padron=112 724 y Padlocal=69 642.

RAW modulo 300 (todas las edades): P306 cod.1=29 438, cod.2=74 897, sin dato=2 623; P314A cod.1=73 888, cod.2=26 031, sin dato=7 039.

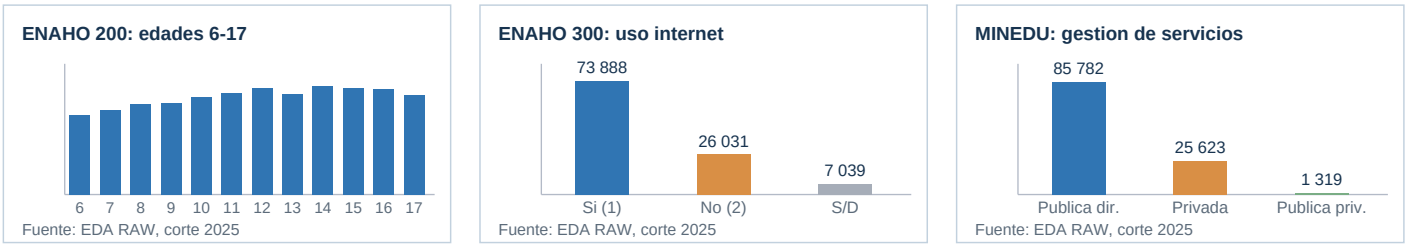


Figura 6. EDA RAW: edades 6-17; P314A en todas las edades; gestiones MINEDU. Los graficos P306 e ingreso/gasto (log1p) se adjuntan como anexos.